적응형 순차 체크리스트 기반 한국어 멀티모달 응답 평가

문정수[1]°, 박채훈[†]
[1]조선대학교, [†]전남대학교
jeongsumoon01@gmail.com, chaehun.park@jnu.ac.kr

Adaptive Sequential Checklist-Based Evaluation of Korean Multimodal Responses

Jeongsu Moon[1], ChaeHun Park[†]
[1]Chosun University, [†]Chonnam National University

요 약

멀티모달 생성 모델이 발전함에 따라 모델이 생성한 응답의 품질을 자동으로 평가하는 시각 언어 모델(VLM) 기반 평가자의 중요성이 커지고 있다. 최근에는 복합적인 품질 기준을 보다 세밀하게 평가하기 위해 응답이 충족해야 하는 조건을 여러 문항으로 세분화하고 개별적으로 검증하는 체크리스트 기반 평가가 연구되고 있다. 그러나 모든 평가 사례에 전체 체크리스트를 적용할 경우 높은 계산 비용이 발생할 수 있다. 본 연구에서는 평가 사례에 따라 필요한 범위까지만 체크리스트 평가를 수행하는 적응형 순차 평가 방법을 제안한다. 제안 방법은 초기 점수 평가에서 선호 응답을 결정하지 못한 경우 체크리스트 평가로 전환하고, 이후 평가 기준을 순차적으로 적용하여 후보 간 점수 차이가 확인되는 시점에 평가를 종료한다. MM-JudgeBench의 한국어 데이터에서 두 종류의 VLM 평가 모델을 사용하여 실험한 결과, 제안 방법은 체크리스트를 적용하지 않은 쌍대비교 방식보다 2.67–18.22%p, 전체 체크리스트 평가보다 1.64–3.46%p 높은 정확도를 기록하였다. 또한 전체 체크리스트 평가 대비 모델 호출 수를 71.9–86.0% 감소시켰다. 이러한 결과는 세부 평가의 적용 범위를 사례별로 조절하는 것이 멀티모달 응답 평가의 정확도를 높이면서 계산 효율성도 개선할 수 있음을 보여준다.

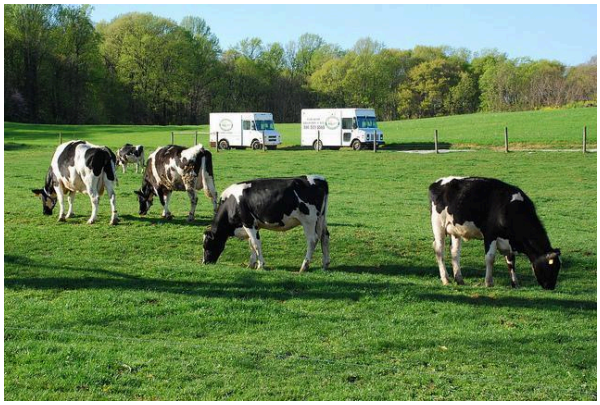
주제어: 멀티모달, 시각 언어 모델, 평가, 체크리스트

제 1. 절 서론

최근 멀티모달 생성 모델의 성능이 빠르게 향상되면서 [1, 2], 생성된 응답의 품질을 신뢰성 있게 평가하는 방법의 중요성이 커지고 있다 [3, 4]. 인간 평가자에 의한 직접 평가는 많은 시간과 비용을 요구하므로, 이를 대신하거나 보조하기 위한 자동 평가 방법으로 시각 언어 모델(VLM)을 평가자로 활용하는 방식이 활발히 연구되고 있다 [5, 4]. 멀티모달 응답의 품질을 평가하기 위해서는 이미지 내용의 정확한 반영 여부, 사용자 질의와의 관련성 및 응답의 명확성, 응답의 완전성과 상세성, 환각이나 근거 없는 주장의 발생 여부 등 다양한 측면을 종합적으로 고려해야 한다 [4]. 그러나 여러 평가 기준을 동시에 고려하는 과정에서 VLM 평가자의 판단이 일관되지 않을 수 있으며, 그 결과 인간 선호와 충분히 일치하지 않는 판정을 내릴 수 있다 [3].

평가 기준을 일관되게 적용하기 위해, 응답의 품질을 종합적으로 판정하는 대신 평가 기준을 여러 개의 검증 가능한 질문으로 분해하고 각 질문에 개별적으로 답하여 해당 조건의 충족 여부를 판정하는 방식이 연구되어 왔다 [6, 7]. 초기 연구에서는 요약문으로부터 질문을 생성하고, 원문을 바탕으로 해당 질문에 답하게 함으로써 사실 일관성을 측정하였다 [6]. 이후 사실성뿐 아니라 자연스러움이나 간결성 등 여러 품질 차원을 개별 질문으로 분해하고, 그 결과를 종합하는 방식으로 확장되었으며 [7], 멀티모달 응답에 대해서도 세분화된 평가 기준을 활용하는 평가 모델이 제안되었다 [8]. 최근에는 이러한 접근을 체크리스트(checklist) 형태로 정형화하여, 응답이 충족해야 하는 조건을 이진형(binary) 문항으로 구성하고 각 문항의 충족 여부를 개별적으로 검증하는 방법들이 제안되었다 [9, 10]. 이러한 세분화된 평가는 복합적인 평가 기준을 개별적으로 검증함으로써 보다 세밀한 응답 평가를 가능하게 한다.

표 1. 한국어 멀티모달 응답 평가 데이터 예시 [4]



질의	이 장면에서 몇 마리의 소가 먹고 있는지 말해 줄 수 있나요?
응답 A	이 장면에는 풀을 뜯고 있는 소 다섯 마리가 있습니다.
응답 B	이 장면에는 풀을 뜯고 있는 소 여섯 마리가 있습니다.

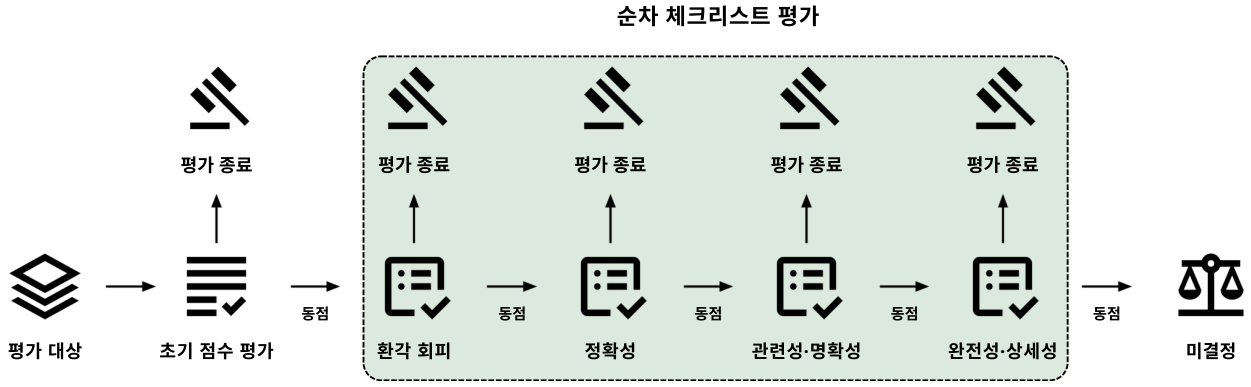


그림 1. 적응형 순차 평가 과정

그러나 체크리스트 기반 평가는 여러 세부 문항을 판정하는 과정에서 모델 호출 수가 증가할 수 있다 [9, 10]. 모든 사례에 동일한 체크리스트를 일괄적으로 적용하면, 일부 기준만으로 판정할 수 있는 사례에도 불필요한 계산 비용이 발생한다 [11]. 체크리스트의 세밀한 평가 능력을 유지하면서, 사례별로 필요한 범위까지만 평가를 수행하여 계산 비용을 줄이는 방법이 필요하다.

본 연구에서는 적응형 순차 평가(adaptive sequential evaluation) 방법을 제안한다. 먼저 두 후보 응답을 독립적으로 평가하고, 초기 점수 평가에서 선호 응답을 결정하지 못한 경우 체크리스트 평가로 전환한다. 체크리스트 단계에서는 단독 적용 정확도가 높은 기준부터 순차적으로 적용하며, 후보 간 점수 차이가 확인되는 시점에 평가를 종료한다. 이를 통해 추가 판단이 필요한 사례에만 세부 평가 기준을 적용한다.

제안 방법의 효과를 검증하기 위해 MM-JudgeBench [4]의 한국어 데이터셋인 M-VL RewardBench(M-VL)와 M-OpenCQA의 총 2,385개 평가 샘플을 대상으로 두 평가 모델 [1, 12]을 사용하였다. 제안 방법은 체크리스트를 적용하지 않은 쌍대비교 방식보다 M-VL에서 10.11–18.22%p, M-OpenCQA에서 2.67–4.19%p 높은 정확도를 보였으며, 전체 체크리스트 평가보다 모델 호출 수를 최대 86.0% 줄였다. 본 연구의 기여를 정리하면 다음과 같다.

- 체크리스트 적용 여부와 후보 응답의 평가 방식을 비교하여, 체크리스트를 쌍대비교에 적용할 때보다 개별 평가에 적용할 때 더 효과적임을 확인한다.
- 두 후보를 먼저 개별 평가하고, 초기 점수 평가에서 선호 응답을 결정하지 못한 경우 평가 기준을 순차적으로 적용하여 후보 간 점수 차이가 확인되면 종료하는 적응형 순차 평가 방법을 제안한다.
- 제안 방법이 전체 체크리스트 평가보다 1.64–3.46%p 높은 정확도를 기록하고, 응답 쌍당 평균 모델 호출 수를 71.9–86.0% 감소시킴을 보인다.

제 2. 절 관련 연구

VLM 기반 멀티모달 평가 대규모 언어 모델(LLM)을 평가자로 활용하는 LLM-as-a-Judge는 인간 평가를 보조하는 확장 가능한 자동 평가 방법으로 널리 활용되고 있다 [13, 14]. 최근에는 연구 범위가 멀티모달 평가로 확장되어, VLM을 평가자로 활용하는 범용 평가 모델이 제안되고 있다 [5].

그러나 멀티모달 평가자의 판단은 인간 선호와 충분히 일치하지 않을 수 있으며, 동일한 두 응답이라도 제시 순서에 따라 판정이 달라지는 순서 편향이 나타날 수 있음이 보고되었다 [3].

체크리스트 기반 평가 Lee et al. [10]은 복합적인 평가 기준을 개별적으로 판정 가능한 이진형 문항으로 분해함으로써 인간 평가와의 상관관계를 높이고 평가 모델 간 일관성을 개선하였다. Furuhashi et al. [11]은 체크리스트의 선택적 적용을 분석하고, 그 효과가 평가 방식에 따라 달라질 수 있음을 보였다. Cook et al. [9]은 응답이 충족해야 하는 요구사항으로부터 체크리스트를 생성하고, 각 조건의 충족 여부를 개별적으로 평가하는 방법을 제안하였다. 본 연구는 체크리스트 단계에서 평가 기준을 순차적으로 적용하고, 두 후보의 점수가 다르면 평가를 종료하여 사례별로 필요한 기준만 적용한다.

제 3. 절 제안하는 방법

3.1 평가 설정

본 연구에서는 이미지 I, 사용자 질의 q, 두 후보 응답 r_A와 r_B가 주어졌을 때 더 적절한 응답을 선택하는 멀티모달 응답 평가를 다룬다. 이러한 평가는 후보 응답을 평가 모델에 제시하는 방식에 따라 **쌍대비교(pairwise evaluation)**와 **개별 평가(pointwise evaluation)**로 구분된다. 쌍대비교에서는 (I, q, r_A, r_B)를 하나의 입력으로 제공하여 두 후보를 직접 비교한다. 반면 개별 평가에서는 (I, q, r_A)와 (I, q, r_B)를 각각 독립적으로 입력하여 점수를 얻고, 높은 점수를 받은 응답을 선호 응답으로 선택한다. 본 연구에서는 체크리스트를 각 후보에

독립적으로 적용하기 위해 개별 평가를 기본 평가 방식으로 사용한다. 이하에서는 평가 방식으로서의 개별 평가와 구분하기 위해, 제안 방법의 첫 단계에서 체크리스트 없이 후보별 점수를 산출하는 단계를 **초기 점수 평가**라 부른다.

3.2 전체 평가 파이프라인

제안 방법은 초기 점수 평가와 순차 체크리스트 평가의 두 단계로 구성된다. 첫 번째 단계인 초기 점수 평가(3.3절)에서는 각 후보를 독립적으로 채점하여 두 후보의 점수가 다른 사례는 이 단계에서 판정을 마치며, 점수가 같거나 유효한 점수를 얻지 못한 사례에 대해서만 두 번째 단계를 수행한다. 두 번째 단계인 순차 체크리스트 평가(3.4절)에서는 네 가지 평가 기준을 사전에 정한 순서에 따라 하나씩 적용하고, 두 후보 간 점수 차이가 확인되는 시점에 평가를 종료한다. 이러한 구조를 통해 모든 사례에 전체 체크리스트를 적용하는 대신, 각 사례에서 선호 응답을 결정하는 데 필요한 평가 기준까지만 적용한다. 전체 평가 과정은 그림 1과 같다.

3.3 초기 점수 평가

초기 점수 평가에서는 두 후보 응답을 각각 독립적으로 평가하여 각 응답에 1–10점 범위의 정수 점수를 부여한다. 두 후보의 점수가 다르면 높은 점수를 받은 응답을 선택하고 평가를 종료한다. 반면 두 후보의 점수가 같거나 유효한 점수를 얻지 못한 경우에는 순차 체크리스트 평가로 전환하여 세부 기준에 따라 두 응답을 추가로 평가한다. 따라서 초기 점수 평가는 추가적인 세부 평가가 필요한 사례를 선별하는 역할을 한다.

3.4 순차 체크리스트 평가

체크리스트 단계에서는 1) 환각 회피, 2) 정확성, 3) 관련성과 명확성, 4) 완전성과 상세성의 네 평가 기준을 순차적으로 적용한다. 각 평가 기준은 20개의 이진형 체크리스트 문항으로 구성되며, 각 문항의 충족 여부를 `YES`/`NO`로 판정한다. 기준별 점수는 해당 기준에서 `YES`로 판정된 문항의 수로 산출한다. 두 후보의 기준별 점수가 다르면 높은 점수를 받은 응답을 선택하고 평가를 종료하며, 점수가 같거나 출력 파싱에 실패한 경우에는 다음 평가 기준을 적용한다.

3.5 체크리스트 문항 구성

체크리스트의 상위 평가 기준으로는 MM-JudgeBench [4]의 VLM 평가 프롬프트에 정의된 네 가지 기준을 사용한다. 각 기준에서 개별적으로 판정 가능한 문항을 도출하기 위해 CheckEval [10]의 단계적 분해 방식을 참고하였다. 각 상위 기준을 다섯 개의 세부 기준으로 분해하고, 각 세부 기준에 대해 네 개의 이진형 체크리스트 문항을 생성하였다. 이에 따라 전체 체크리스트는 후보 응답당 총 80개 문항으로 구성된다.

표 2. 평가 기준별 체크리스트 문항 예시

상위 평가 기준	체크리스트 문항 예시
환각 회피	응답에서 제시한 수량이 이미지에서 확인되는가?
정확성	응답에서 언급한 객체가 이미지의 내용과 일치하는가?
관련성과 명확성	응답이 사용자의 질문에 직접적으로 대응하는가?
완전성과 상세성	응답이 질문에 필요한 핵심 정보를 빠짐없이 포함하는가?

표 3. M-VL 체크리스트 · 평가 방식별 정확도(%)

평가 모델	체크리스트	쌍대비교	개별 평가
Qwen	미적용	**61.53**	54.20
	전체 적용	48.86	**68.30**
Gemma	미적용	**42.50**	14.59
	전체 적용	43.11	**58.03**

문항 생성에는 `gpt-5.6-sol`을 사용하였으며, 각 문항을 조건의 충족 여부에 대해 `YES`/`NO`로 답할 수 있는 형태로 구성하였다. 후보 응답 하나를 평가할 때 동일한 세부 기준의 네 문항을 한 번의 모델 호출로 함께 판정하므로, 상위 평가 기준별로 5회, 네 기준 전체에 총 20회의 모델 호출이 필요하다. 따라서 응답 쌍당 총 40회의 모델 호출이 요구된다. 모든 문항은 `YES`가 해당 품질 조건의 충족을 의미하도록 구성하였다. 생성 시에는 상위 평가 기준과 구성 지시만 입력하였으며 실제 평가 사례는 포함하지 않았다. 평가 기준별 문항 예시는 표 2에 제시한다.

제 4. 절 실험

4.1 데이터셋

본 연구에서는 MM-JudgeBench [4]의 한국어 데이터 중 M-VL RewardBench(M-VL)와 M-OpenCQA를 사용하였다. MM-JudgeBench는 영어 기반 벤치마크를 25개 언어로 확장한 다국어 멀티모달 평가 벤치마크이다. 원본 이미지는 그대로 유지하고 사용자 질의와 후보 응답만 번역하였으며, 각 평가 샘플은 하나의 이미지와 질의, 두 후보 응답, 그리고 두 후보에 대한 인간 선호 레이블로 구성된다.

M-VL은 VL-RewardBench [15]를 다국어로 확장한 시각 언어 선호 평가 데이터셋으로, 일반적인 멀티모달 질의와 시각적 환각, 복합 추론 과제를 포함한다. M-OpenCQA는 개방형 차트 질의응답 데이터셋 OpenCQA [16]를 기반으로 구성되며, 차트 이미지에 대한 개방형 질문과 두 개의 서술형 후보 응답을 포함한다. 본 연구에서는 M-VL과 M-OpenCQA에서 각각 1,227개와 1,158개의 평가 샘플을 사용하였다.

4.2 평가 모델 및 추론 설정

평가 모델로 Qwen3-VL-8B-Instruct [1](이하 Qwen)와 Gemma-3-12B-IT [12](이하 Gemma)를 사용하였다. 초기 점수 평가에는 MM-JudgeBench [4]의 VLM 쌍대비교 프롬프트를 개별 평가 형식으로 변형하여 사용하였다. 원 프롬프트의 네 가지 평가 기준은 유지하되, 두 후보를 함께 제시하는 대신 각 후보를 독립적으로 평가하고 응답 품질을 1–10점의 정수로 출력하도록 구성하였다. 실험은 NVIDIA RTX PRO 5000 72 GB GPU 1장을 이용하여 수행하였다. 모든 추론에는 greedy decoding을 적용하였다. 최대 출력 길이는 초기 점수 평가와 체크리스트 평가에서 각각 320토큰과 64토큰으로 설정하였다.

초기 점수 평가의 출력 파싱에 실패하면 형식 지시를 보강하여 한 차례 재요청하고, 이후에도 실패하면 체크리스트 단계로 전환하였다. 체크리스트 출력 파싱에 실패한 경우에는 해당 기준에서 선호 응답을 결정하지 않고 다음 평가 기준을 적용하였으며, 마지막 기준까지 두 후보 간 차이가 확인되지 않은 경우에는 미결정으로 처리하였다.

4.3 평가 지표

평가 모델의 성능은 **정확도**로 측정하였다. 정확도는 모델이 선택한 응답이 인간 평가자가 선호한 응답과 일치하는 평가 샘플의 비율로 정의되며, 미결정 사례는 오답으로 간주하였다. 또한 쌍대비교 방식의 순서 편향을 분석하기 위해 정확도 차이와 판정 변경률을 측정하였다. **정확도 차이**는 후보 응답의 원래 제시 순서(정방향)와 이를 뒤바꾼 순서(역방향)에서 얻은 정확도의 절대 차이이며, **판정 변경률**은 정방향과 역방향의 최종 판정이 서로 다른 평가 샘플의 비율로 정의된다. 두 지표를 함께 사용하여 정확도 차이만으로 포착하기 어려운 판정 불안정성을 분석하였다.

제 5. 절 실험 결과

5.1 체크리스트와 평가 방식 비교

비교 방법 체크리스트 적용 여부와 후보 응답의 평가 방식이 성능에 미치는 영향을 분석하기 위해 두 요인을 조합한 2×2 비교 실험을 수행하였다. 첫 번째 요인은 체크리스트 적용 여부이다. 두 번째 요인은 평가 방식이며, 두 후보를 함께 비교하는 쌍대비교와 각 후보를 독립적으로 평가하는 개별 평가로 구분된다. 이에 따라 총 네 가지 평가 조건을 구성하였으며, 표 3은 M-VL 데이터셋에서 각 조건의 평가 정확도를 보여준다. 쌍대비교 정확도는 정방향과 역방향 평가 결과의 평균으로 산출하였다.

실험 결과 체크리스트의 효과는 후보 응답의 평가 방식에 따라 다르게 나타났다. 체크리스트를 적용하지 않았을 때 개별 평가의 정확도는 쌍대비교보다 낮았다(Qwen: 54.20% vs. 61.53%, Gemma: 14.59% vs. 42.50%). Gemma의 개별 평가에서는 두 후보가 동일한 점수를 받은 비율이 70.01%에 달하였다. 체크리스트를 적용한 개별 평가의 정확도는 Qwen 68.30%, Gemma 58.03%로 향상되었으며, 체크리스트 기반 쌍대비교의 정확도(각각 48.86%, 43.11%)를 모두 상회하였다. 이는 체크리스트가 쌍대비교보다 개별 평가에 적용될 때 더 효과적으로 작용하였음을 보여준다.

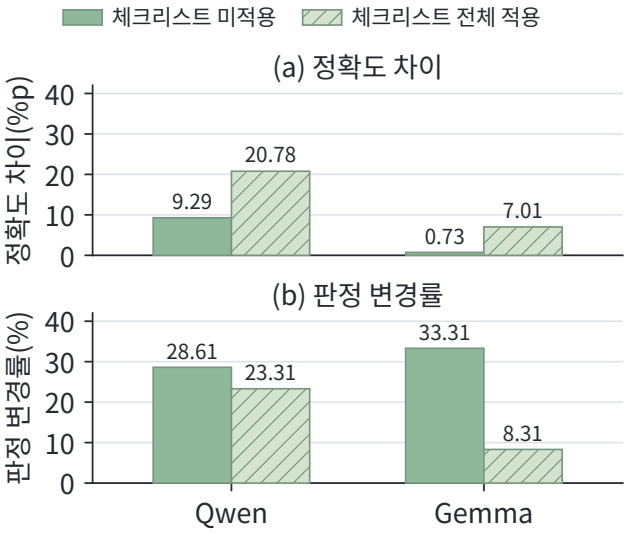


그림 2. M-VL 쌍대비교 평가의 순서 편향

제시 순서에 따른 판정 변경 그림 2는 후보 응답의 제시 순서를 바꾸었을 때의 정확도 차이와 판정 변경률을 보여준다. 체크리스트를 적용하지 않은 쌍대비교의 정확도 차이는 Qwen 9.29%p, Gemma 0.73%p였지만, 판정 변경률은 각각 28.61%와 33.31%로 나타났다. 이는 전체 정확도의 변화가 작더라도 개별 사례에서는 제시 순서에 따라 판정이 빈번하게 달라질 수 있음을 보여준다. 체크리스트를 적용한 경우 판정 변경률은 Qwen 23.31%, Gemma 8.31%로 감소하였지만, 정확도 차이는 각각 20.78%p와 7.01%p로 증가하였다. 따라서 쌍대비교의 순서 편향을 분석할 때는 정확도 차이와 판정 변경률을 함께 고려해야 한다.

5.2 적응형 순차 평가

평가 기준의 적용 순서 순차 평가에서는 후보 간 점수 차이가 확인되면 평가를 종료하므로, 기준의 적용 순서에 따라 최종 판정과 모델 호출 수가 달라질 수 있다. 본 연구에서는 M-VL에서 각 기준을 단독으로 적용하였을 때의 정확도를 바탕으로 적용 순서를 정하였다. 그림 3에서 환각 회피와 정확성은 두 평가 모델에서 높은 정확도를 보였고, 관련성과 명확성은 완전성과 상세성 기준과 같거나 더 높은 정확도를 보였다. 이에 따라 평가 기준을 환각 회피, 정확성, 관련성과 명확성, 완전성과 상세성 순으로 적용하였다.

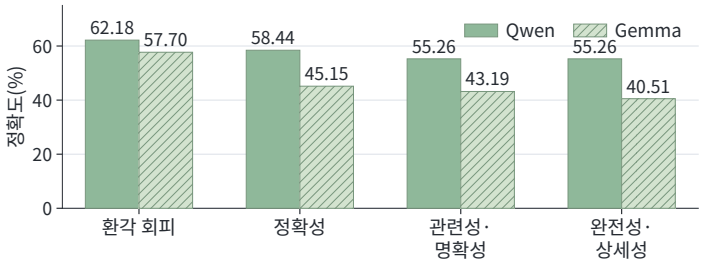


그림 3. M-VL 체크리스트 기준별 정확도(%)

표 4. M-VL · M-OpenCQA 평가 방법별 정확도(%)

평가 모델	평가 방법	M-VL	M-OpenCQA
Qwen	쌍대비교	61.53	65.98
	전체 체크리스트	68.30	67.01
	적응형 순차 평가	**71.64**	**68.65**
Gemma	쌍대비교	42.50	60.32
	전체 체크리스트	58.03	61.05
	적응형 순차 평가	**60.72**	**64.51**

그림 4는 초기 점수 평가 이후, 앞선 단계에서 판정되지 않은 사례에 다음 평가 기준을 순차적으로 적용하였을 때의 정확도 변화를 보여준다. 두 평가 모델 모두 첫 번째 기준인 환각 회피를 적용한 단계에서 정확도가 크게 향상되었으며, 이후 기준을 추가하였을 때의 변화는 상대적으로 작았다. 이는 현재의 기준 순서에서 첫 번째 기준만으로도 정확도 향상의 상당 부분이 나타났음을 보여준다.

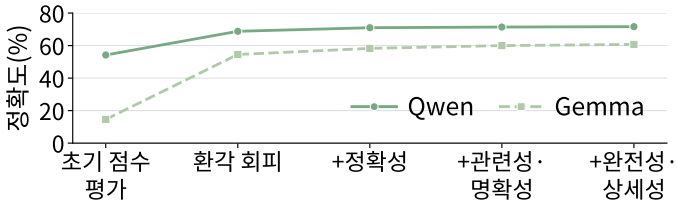


그림 4. M-VL 순차 체크리스트 단계별 정확도(%)

정확도 및 계산 효율성 표 4와 표 5는 각각 평가 방법별 정확도와 응답 쌍당 평균 모델 호출 수를 보여준다. 표 4에서 쌍대비교 정확도는 체크리스트를 적용하지 않은 정방향과 역방향 평가 결과의 평균으로 산출되었으며, 전체 체크리스트 평가와 적응형 순차 평가는 개별 평가 방식으로 수행되었다. 표 5에서 쌍대비교는 정방향과 역방향 평가를 각각 1회씩 수행하므로 응답 쌍당 총 2회의 모델 호출이 필요하다. 제안 방법은 두 데이터셋과 두 평가 모델의 모든 조건에서 가장 높은 정확도를 기록하였으며, 전체 체크리스트 평가보다 1.64–3.46%p 높은 정확도를 보였다. 또한 응답 쌍당 평균 모델 호출 수를 전체 체크리스트 평가 대비 71.9–86.0% 감소시켰다. 이러한 결과는 정확도가 높은 평가 기준을 우선적으로 적용하고 후보 간 점수 차이가 확인되면 평가를 종료하는 방식이 전체 체크리스트를 적용하는 것보다 적은 모델 호출로 높은 정확도를 달성할 수 있음을 보여준다.

표 5. 평가 방법별 응답 쌍당 평균 호출 횟수

평가 모델	평가 방법	M-VL	M-OpenCQA
Qwen	쌍대비교	2.00	2.00
	전체 체크리스트	40.00	40.00
	적응형 순차 평가	**5.59**	**5.71**
Gemma	쌍대비교	2.00	2.00
	전체 체크리스트	40.00	40.00
	적응형 순차 평가	**11.25**	**10.72**

표 6. 표 1 사례의 적응형 순차 평가 결과

평가 항목	응답 A	응답 B
초기 점수 평가	10	10
환각 회피 점수(20문항)	**8**	6
두 후보의 충족 여부가 다르게 판정된 체크리스트 문항		
응답에서 제시한 수량이 이미지에서 확인되는가?	YES	NO
응답의 확신 수준이 이미지에서 확인되는 근거의 강도에 부합하는가?	YES	NO

사례 분석 표 6은 표 1에 제시한 사례의 단계별 평가 결과를 보여준다. 초기 점수 평가에서 두 후보가 모두 10점을 받아 순차 체크리스트 평가로 전환되었으며, 첫 번째 기준인 환각 회피에서 응답 A가 8점, 응답 B가 6점을 받아 응답 A가 선택되었다. 두 후보의 점수 차이가 확인된 시점에 평가를 종료하였으므로 이후의 정확성, 관련성과 명확성, 완전성과 상세성 기준은 적용되지 않았다. 이 사례는 초기 점수 평가만으로 구분되지 않은 후보를 세부 체크리스트를 통해 구분하고, 조기 종료를 통해 이후 평가 기준에 대한 불필요한 모델 호출을 줄이는 과정을 보여준다.

제 6. 절 결론

본 연구에서는 멀티모달 응답 평가에서 체크리스트 기반 평가의 정확도와 계산 비용 간 균형을 개선하기 위한 적응형 순차 평가 방법을 제안하였다. 제안 방법은 두 후보 응답을 먼저 독립적으로 평가하고, 초기 점수 평가에서 선호 응답을 결정하지 못한 경우 체크리스트 평가를 수행하며, 두 후보의 점수 차이가 확인되면 평가를 종료한다. 한국어 멀티모달 평가 벤

치마크에서 두 종류의 VLM 평가 모델을 사용한 결과, 제안 방법은 체크리스트를 적용하지 않은 쌍대비교 방식보다 2.67–18.22%p, 전체 체크리스트 평가보다 1.64–3.46%p 높은 정확도를 기록하였다. 또한 전체 체크리스트 평가 대비 모델 호출 수를 71.9–86.0% 감소시켰다. 이러한 결과는 모든 평가 사례에 동일한 세부 평가를 적용하는 대신 사례별로 필요한 범위까지만 평가하는 방식이 멀티모달 응답 평가의 정확도를 높이면서 계산 효율성도 개선할 수 있음을 보여준다.

본 연구의 한계는 다음과 같다. 첫째, M-VL에서 각 평가 기준의 단독 적용 정확도를 바탕으로 순서를 결정하는 오라클 기준 순서(oracle criterion ordering)를 사용하였으므로, M-VL 결과에는 평가 데이터에 기반한 순서 선택의 이점이 포함될 수 있다. 둘째, 모델 호출 수를 중심으로 계산 효율성을 평가하여 단계별 입력 길이, 토큰 사용량 및 추론 시간의 차이를 충분히 반영하지 못하였다. 셋째, 초기 점수 평가의 효과가 평가 모델에 따라 달라지므로 제안 방법의 효율성이 모델 특성에 영향을 받을 수 있다. 마지막으로 두 개의 한국어 데이터셋과 두 종류의 VLM만을 사용하였기 때문에 결과의 일반화 가능성이 제한된다. 향후에는 별도의 검증 데이터에서 평가 기준의 순서를 결정하고, 다양한 언어와 과제 및 평가 모델을 대상으로 토큰 사용량과 추론 시간을 포함한 종합적인 평가를 수행할 필요가 있다.

감사의 글

This research was supported by the National Research Foundation of Korea (NRF) grant funded by the Korea government (MSIT) (RS-2026-25597771, 40%), the Basic Science Research Program through the National Research Foundation of Korea (NRF) funded by the Ministry of Education (RS-2025-25398164, 30%), and the Institute of Information & Communications Technology Planning & Evaluation (IITP, AI Computing Support Project for R&D) grant funded by the Korea government (MSIT) (RS-2026-25505492, High-Performance Research AI Computing Infrastructure Support at the 2 PFLOPS Scale, 30%).

참고문헌

[1] S. Bai *et al.*, "Qwen3-VL technical report," *arXiv preprint arXiv:2511.21631*, 2025.

[2] X. An *et al.*, "LLaVA-OneVision-2: Towards next-generation perceptual intelligence," *arXiv preprint arXiv:2605.25979*, 2026.

[3] D. Chen *et al.*, "MLLM-as-a-judge: Assessing multimodal LLM-as-a-judge with vision-language benchmark," *Proc. of ICML*, 2024.

[4] M. T. R. Laskar *et al.*, "Lost in translation: Do LVLM judges generalize across languages?" *Findings of ACL*, 2026.

[5] T. Xiong *et al.*, "LLaVA-Critic: Learning to evaluate multimodal models," *Proc. of CVPR*, 2025.

[6] A. Wang *et al.*, "Asking and answering questions to evaluate the factual consistency of summaries," *Proc. of ACL*, 2020.

[7] H. Hashemi *et al.*, "LLM-Rubric: A multidimensional, calibrated approach to automated evaluation of natural language texts," *Proc. of ACL*, 2024.

[8] S. Lee *et al.*, "Prometheus-vision: Vision-language model as a judge for fine-grained evaluation," *Findings of ACL*, 2024.

[9] J. Cook *et al.*, "TICKing all the boxes: Generated checklists improve LLM evaluation and generation," *Proc. of the NeurIPS Workshop on Language Gamification*, 2024.

[10] Y. Lee *et al.*, "CheckEval: A reliable LLM-as-a-judge framework for evaluating text generation using checklists," *Proc. of EMNLP*, 2025.

[11] M. Furuhashi *et al.*, "Are checklists really useful for automatic evaluation of generative tasks?" *Proc. of EMNLP*, 2025.

[12] Gemma Team, "Gemma 3 technical report," *arXiv preprint arXiv:2503.19786*, 2025.

[13] L. Zheng *et al.*, "Judging LLM-as-a-judge with MT-Bench and chatbot arena," *Proc. of NeurIPS*, 2023.

[14] Y. Liu *et al.*, "G-Eval: NLG evaluation using GPT-4 with better human alignment," *Proc. of EMNLP*, 2023.

[15] L. Li *et al.*, "VL-RewardBench: A challenging benchmark for vision-language generative reward models," *Proc. of CVPR*, 2025.

[16] S. Kantharaj *et al.*, "OpenCQA: Open-ended question answering with charts," *Proc. of EMNLP*, 2022.